

CORPORACIÓN UNIVERSITARIA MINUTO DE DIOS – UNIMINUTO

Taller de simulación de un sistema básico de inteligencia artificial

Julian David Rodriguez Cortes

Inteligencia Artificial

NRC: 45- 73657

Nombre del tutor: ZAIDA PATRICIA OJEDA GUZMAN

Bogotá DC

24/05/2026

Link GitHub: <https://github.com/JulianRodriguez24/Inteligencia-Artificial.git>

Análisis asistido con IA generativa:

IA Utilizada: Claude

Sobre la confiabilidad — el accuracy miente

El 96.8% de accuracy suena excelente, pero es una métrica engañosa en este caso. Si el modelo simplemente dijera "sin diabetes" para todos los pacientes, ya tendría 91.5% de accuracy sin haber aprendido nada. La métrica real a vigilar es el **recall sobre la clase diabética**, que ronda el 79%, lo que significa que aproximadamente 1 de cada 5 pacientes diabéticos no sería detectado. En un contexto clínico, ese es el error más grave posible.

Sobre los sesgos — el problema está en los datos

Hay dos fuentes de sesgo importantes. Primero, las variables categóricas (gender = "Other", smoking_history = "No Info") representan datos incompletos que el modelo aprende como si fueran categorías válidas. Segundo, el LabelEncoder asigna números ordenados a categorías sin orden real, lo que puede hacer creer al modelo que "former" > "current" > "never" en términos de magnitud, cuando eso no tiene sentido clínico.

Sobre los riesgos éticos — tres niveles de preocupación

El más inmediato es el del **falso negativo**: un paciente diabético no detectado puede no recibir tratamiento oportuno. El segundo es la **opacidad de la red neuronal**: un médico no puede explicarle a su paciente por qué el modelo lo clasificó de cierta forma, lo que viola principios básicos de medicina y regulaciones como el derecho a la explicación del GDPR. El tercero es el riesgo de **automatización sin supervisión**, que en la práctica ocurre cuando una herramienta de apoyo se convierte gradualmente en la que toma las decisiones.

Sobre las limitaciones técnicas — qué cambiaría primero

La prioridad es tratar el desbalance de clases con SMOTE o ajustando el parámetro class_weight='balanced' directamente en Keras. Esto sería de mayor impacto que cualquier ajuste de arquitectura. Después, reemplazar LabelEncoder por OneHotEncoder para las variables nominales, y añadir validación cruzada para que los resultados no dependan de una sola partición aleatoria.

Sobre las recomendaciones — la más importante es no técnica

Antes de cualquier mejora de código, se debe definir formalmente el rol del modelo: es una herramienta de cribado, no de diagnóstico. Ese documento de gobernanza es lo que separa un prototipo académico de un sistema responsable.

reflexión Final:

- Aprendizajes obtenidos: Con forme al desarrollo del notebook adaptado al dataset (diabetes_prediccion_dataset.csv) se permitió comprender el ciclo completo de un proyecto de inteligencia artificial aplicado a un caso real en el sector de la salud. Desde la carga y exploración del dataset hasta la generación de predicciones.
- Entender que las variables categóricas como genero e historial de tabaquismo requieren codificación antes de ser procesadas por una red neuronal y que su forma de codificación puede afectar el aprendizaje del modelo.
- El accuracy como métrica aislada puede ser engañosa. En dataset desbalanceados, métricas como recall, F1-score y AUC-ROC aportan una visión mas honesta del desempeño real del modelo.

Dificultades encontradas:

- El dataset presenta un marcado desbalance entre pacientes diabéticos y los no diabéticos. Esto requiere atención ya que el modelo puede alcanzar un accuracy del 91% simplemente prediciendo siempre la clase mayoritaria, sin haber aprendido nada sobre la enfermedad.
- Distinguir entre precisión y recall fue inicialmente confuso ya que en diagnostico médico. El recall sobre la clase positiva (detecta a todos los diabéticos) es mas critico que la precisión, porque el costo de no detectar a alguien que si tiene diabetes es mucho mas grave que un falso positivo.

Importancia de los datos:

- Si el dataset no refleja con fidelidad la población real de pacientes (por ejemplo, si está sesgado hacia ciertos grupos de edad o procedencias geográficas), el modelo fallará sistemáticamente en los grupos subrepresentados, precisamente aquellos que más podrían necesitar detección temprana.
- Si hay una lección central de este taller, es que los datos son el fundamento de cualquier sistema de inteligencia artificial. Un modelo sofisticado con datos de mala calidad producirá predicciones poco confiables. Por el contrario, datos bien curados y representativos pueden compensar arquitecturas más simples.

Riesgos asociados a la automatización de decisiones:

- Falsos negativos con consecuencias graves un paciente diabético clasificado como sano podría no recibir seguimiento, tratamiento preventivo ni cambios en su estilo de vida. Las complicaciones derivadas de un diagnóstico tardío incluyen daño renal, cardiovascular y neuropatía, todas prevenibles con detección oportuna.
- Opacidad y falta de explicabilidad una red neuronal no puede decirle a un médico ni a un paciente por qué llegó a una conclusión. En un contexto donde la transparencia es un derecho del paciente, un modelo que no puede justificar sus predicciones no debería ser la base de ninguna decisión clínica relevante.
- Ausencia de marco regulatorio claro en Colombia y en gran parte de América Latina, la regulación sobre el uso de IA en salud aún está en desarrollo. Esto genera una zona gris donde sistemas no validados pueden desplegarse sin los controles necesarios.